NLP

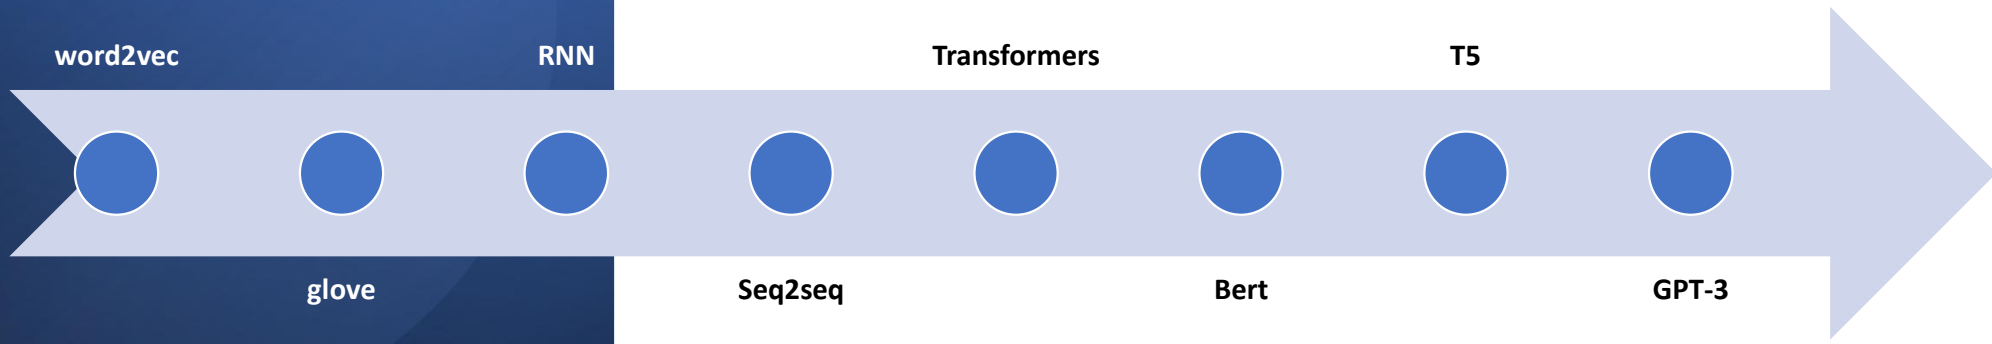

Transformer

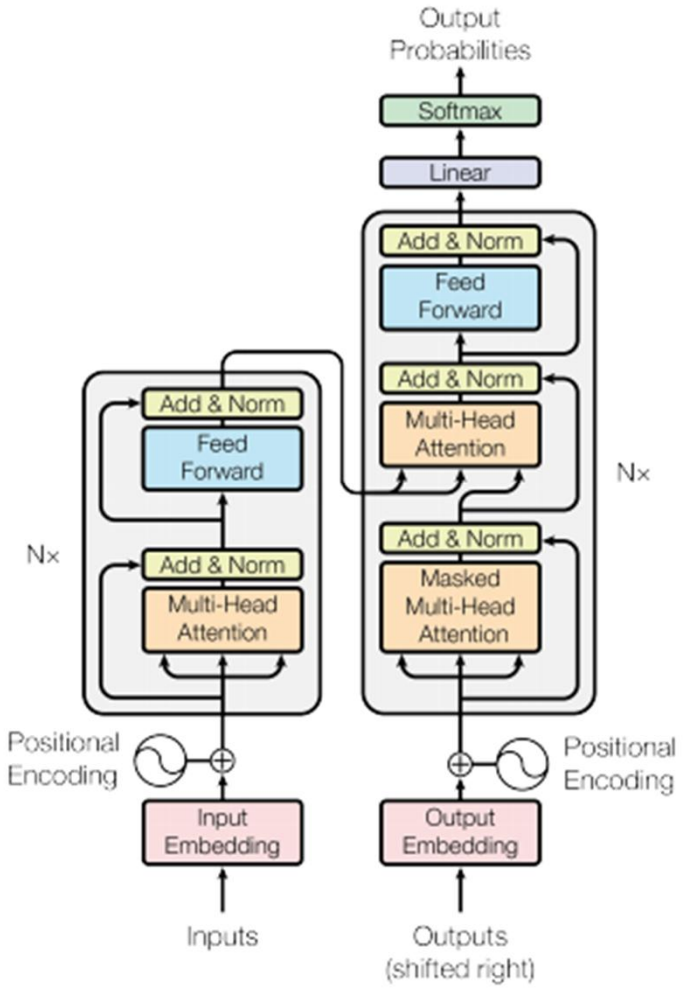

Transformers

- Modelo Revolucionário
- Utilizado em GPT-3, T5 e BERT
- Não usa recorrência como RNN
- Basedo no mecasimo de atenção “Attention”
- Arquitetura ENDEC

Attention / Self Attention

- Attention aprende a relação contextual entre palavras
- Wor2vec não!
- Precisa ser treinado
- Existem modelos pré-treinados

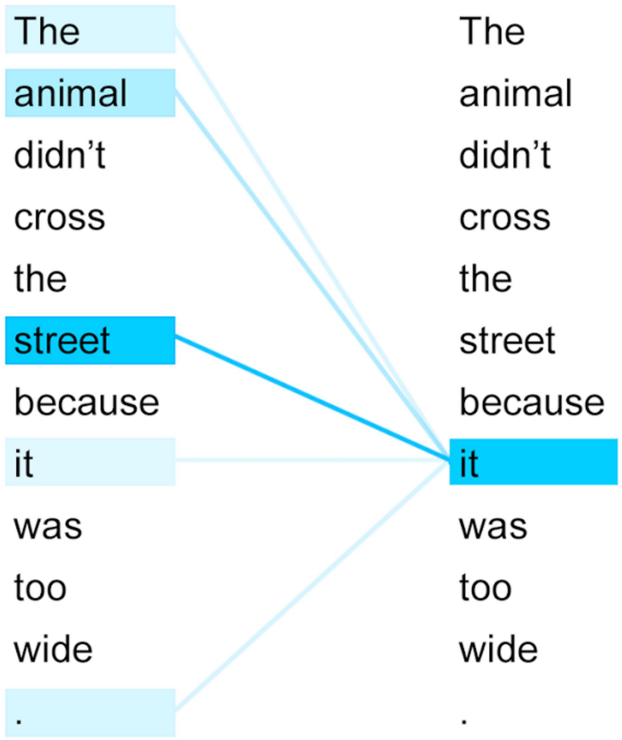

https://ai.googleblog.com/2017/08/transformer-novel-neural-network.html

ENDEC: Encode / Decode

- Encoder : Colocar a mensagem em um formato que o computador compreenda
- Decoder: Colocar a mensagem em de volta ao formato original*

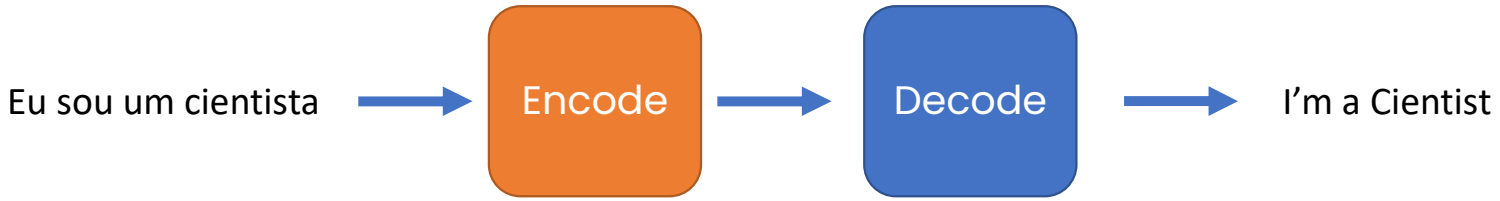

Transformer: Encoder

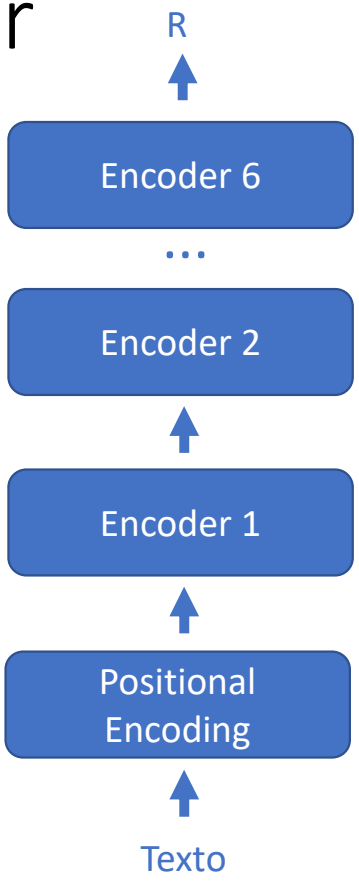

Positional Encoding

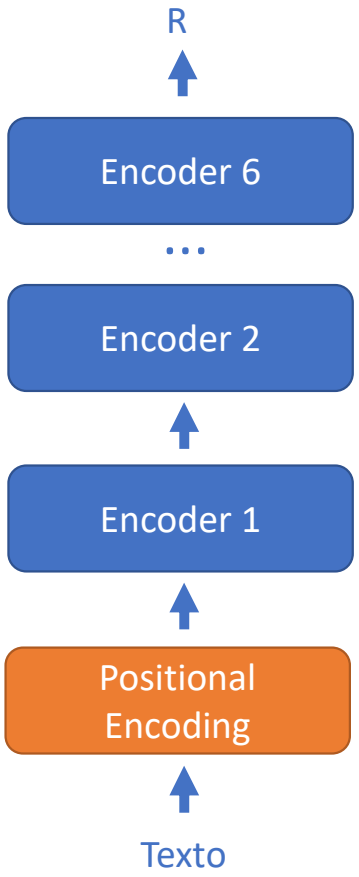

Positional Encoding

- NLP depende de ordem
- É natural processar em sequência
- A maioria das técnicas processam dados que dependem de Recorrência (RNN)
- Porém um Transformer submete texto (Embedding) em paralelo
  - Performance e melhoras no aprendizado

Positional Encoding

- Matriz com mesmas dimensões do embedding

The	0,42	0,70	0,04	...
Law	0,70	0,62	0,80	...
Will	0,17	0,04	0,41	...

Embedding Original

+

The	0,61	0,52	0,89	...
Law	0,17	0,29	0,16	...
Will	0,62	0,39	0,08	...

PE

=

The	1,04	1,22	0,93	...
Law	0,87	0,91	0,96	...
Will	0,79	0,43	0,49	...

Embedding Final

Positional Encoding

- Com a matriz PE é calculada?
  - Usa da função senoidal
  - *pos* é posição da palavra na sentença
  - *i* a posição no embedding
  - Seno quando é par e coseno quando é impar

$$PE_{(POS,2i)} = \sin(\frac{pos}{10000^{2i/d_{model}}})$$

$$PE_{(POS,2i)} = \cos(\frac{pos}{10000^{2i/d_{model}}})$$

Transformer

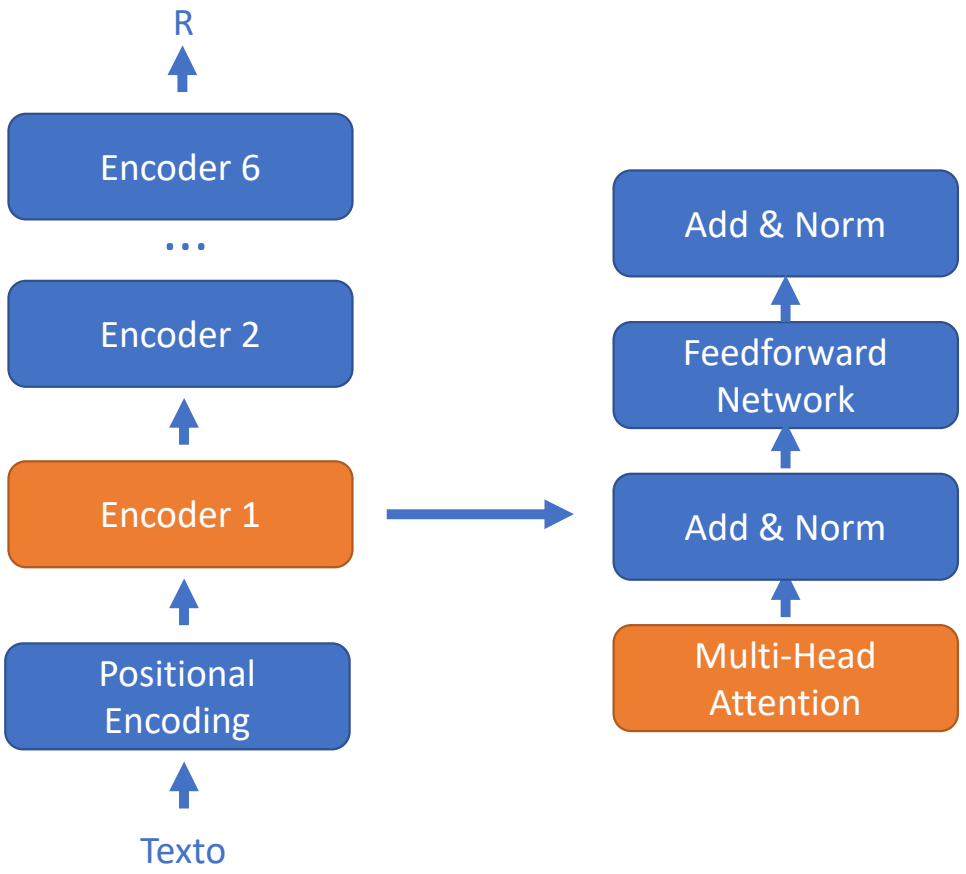

Self-attention

- A função é descobrir a relação entre as palavras
- *It* se refere a *animal* ou *street*?
- Como saber a qual se refere?

- O transformer calcula a representação e a relação de cada palavra
- Assim ele compreende que it se refere *street* e não a *animal*

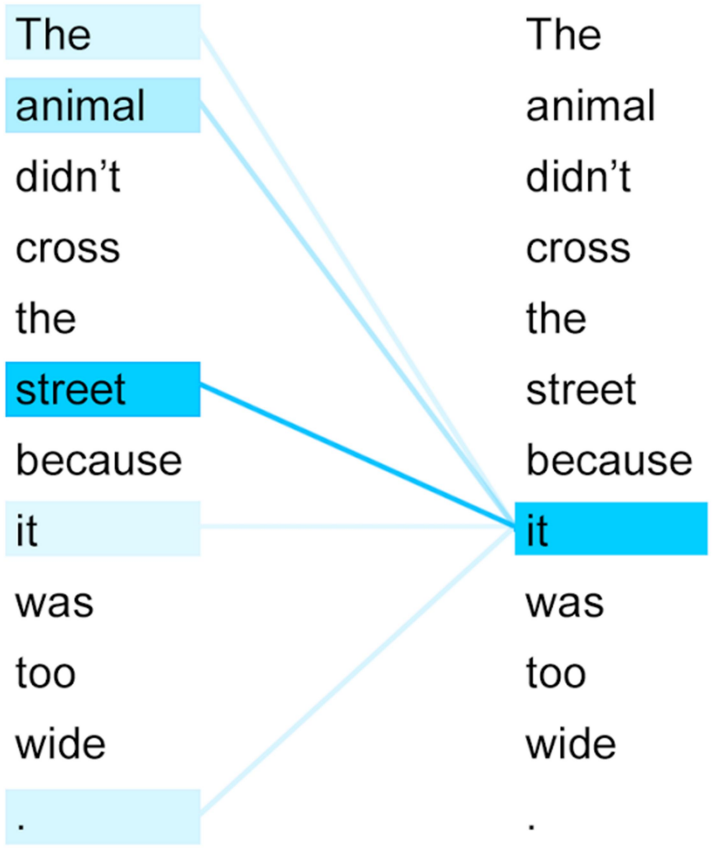

Self-attention

- Self-attention é o resultado do processamento
- Mostra que *it* tem um peso maior para *street*
- Como ele descobre a relação?
  - 5 etapas!

1. Matrizes Q,K e V

- The Animal Didn’t (...)
- Produz o embedding da sentença gerando matriz X
- Dimensões de X é o da sentença * tamanho do embedding [3 x 300]
- Três novas matrizes ponderadas são geradas
  - Q: query matrix
  - K: key matrix
  - V: Value matrix
- Pesos são ajustados durante o treinamento

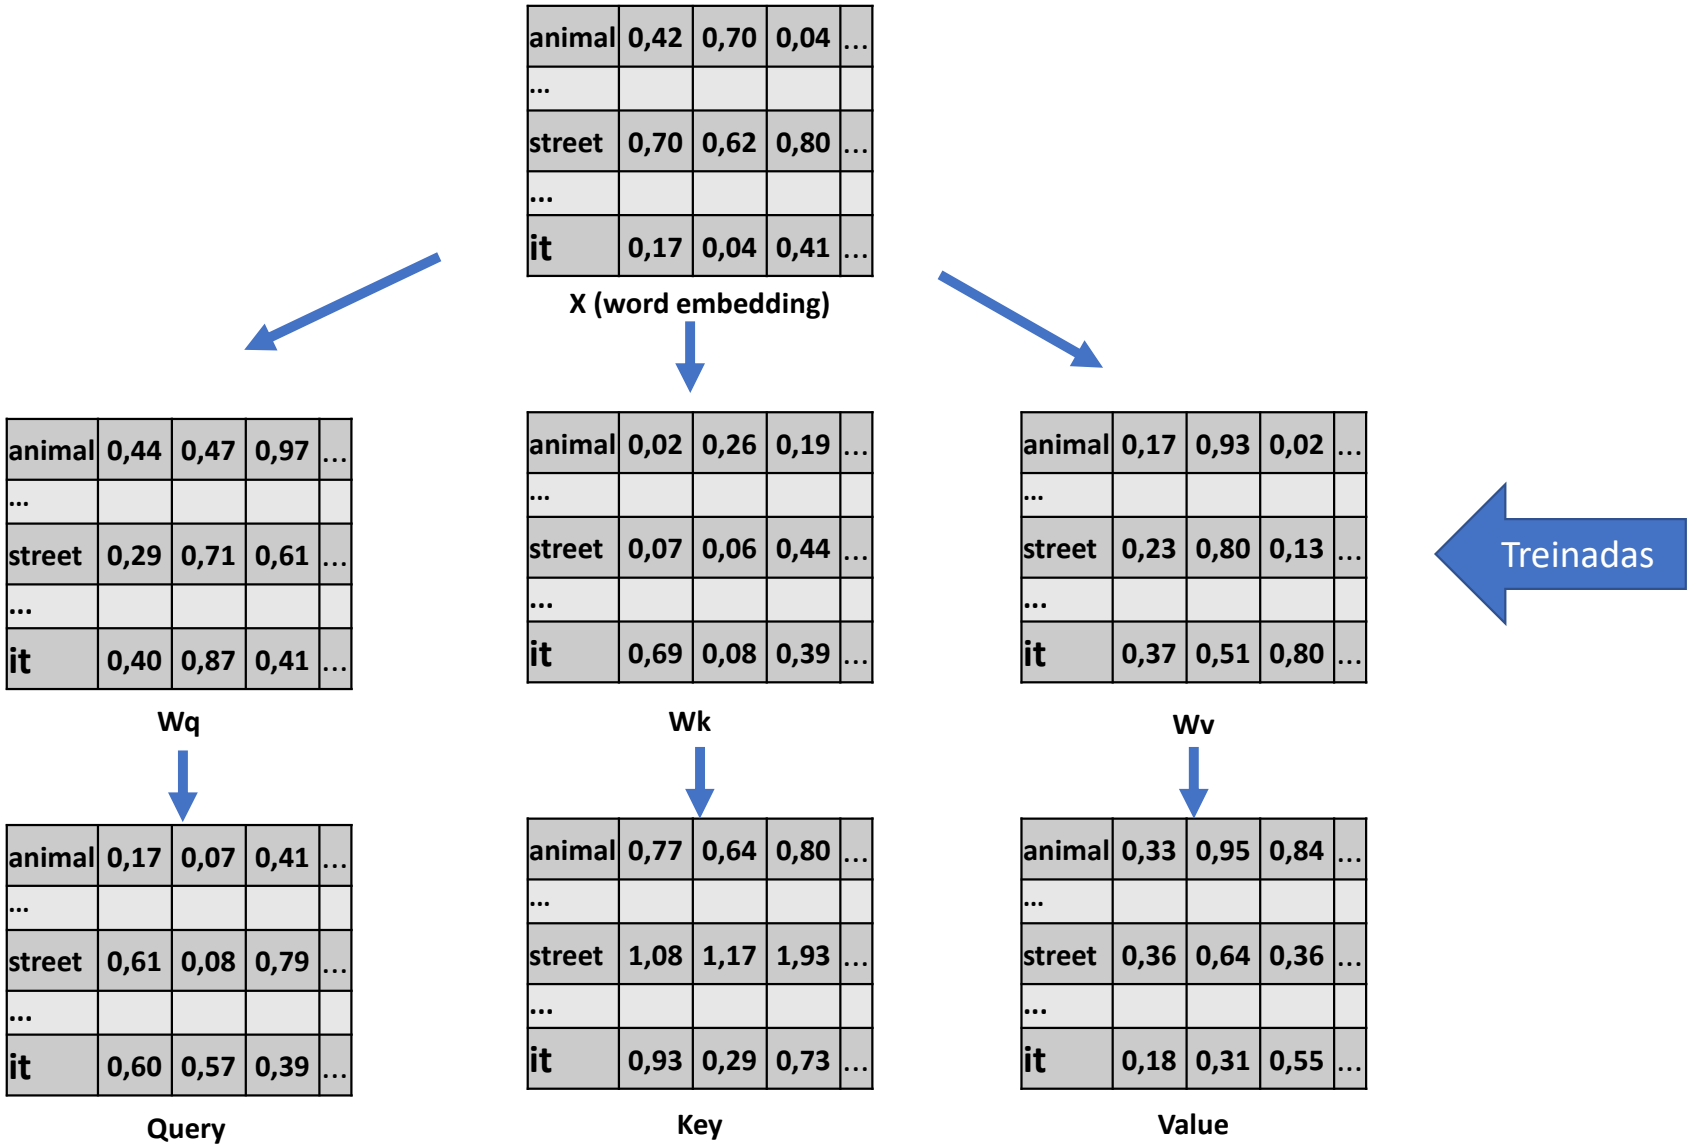
animal 0,42 0,70 0,04 ...
...
street 0,70 0,62 0,80 ...
...
it 0,17 0,04 0,41 ...
X (word embedding)
animal 0,44 0,47 0,97 ...
...
street 0,29 0,71 0,61 ...
...
it 0,40 0,87 0,41 ...
Wq
animal 0,02 0,26 0,19 ...
...
street 0,07 0,06 0,44 ...
...
it 0,69 0,08 0,39 ...
Wk
animal 0,17 0,93 0,02 ...
...
street 0,23 0,80 0,13 ...
...
it 0,37 0,51 0,80 ...
Wv
Treinadas
animal 0,17 0,07 0,41 ...
...
street 0,61 0,08 0,79 ...
...
it 0,60 0,57 0,39 ...
Query
animal 0,77 0,64 0,80 ...
...
street 1,08 1,17 1,93 ...
...
it 0,93 0,29 0,73 ...
Key
animal 0,33 0,95 0,84 ...
...
street 0,36 0,64 0,36 ...
...
it 0,18 0,31 0,55 ...
Value

2º: Score: Produto escalar entre Query e Key

- Mostra o grau de similaridade entre palavras

animal	0,17	0,07	0,41	…
…				
street	0,61	0,08	0,79	…
…				
it	0,60	0,57	0,39	…

Query

x

animal	0,77	0,64	0,80	…
…				
street	1,08	1,17	1,93	…
…				
it	0,93	0,29	0,73	…

Key

=

animal	0,33	0,95	0,84	…
…				
street	0,36	0,64	0,36	…
…				
it	0,18	0,31	0,55	…

Value

3º: Dividir QK pela raiz quadrada das dimensões de Key

- Objetivo: obter bons gradientes

$$\frac{QK^T}{\sqrt{D_X}}$$

4º Produção da Score Matrix

- Normalização entre 0 e 1 com softmax
- Objetivo é gerar um score de relação entre as palavras

$$\text{softmax}\left(\frac{QK^T}{\sqrt{D_K}}\right)$$

animal	0,17	0,07	0,41	…
…				
street	0,61	0,08	0,79	…
…				
it	0,60	0,57	0,39	…

Score

5º:Calcular a matriz Z (matriz de atenção)

- Cálculo é Score Matrix * V
- Cada palavra terá um score: Z_1, Z_2,Z_3
- Mostra o peso da relação entre as palavras

	animal	street	it	
animal	0,83	0,07	0,41	…
…				
street	0,61	0,08	0,79	…
…				
it	0,60	0,57	0,39	…

Score

x

	animal	street	it	
animal	0,33	0,95	0,84	…
…				
street	0,36	0,64	0,36	…
…				
it	0,18	0,31	0,55	…

Value

Attention

$$\text{softmax}\left(\frac{QK^T}{\sqrt{D_K}}\right) * V$$

- A matriz Z está pronta para ser enviadas através da próxima camada Feedforward Network (porém antes será normalizada)

Encoder

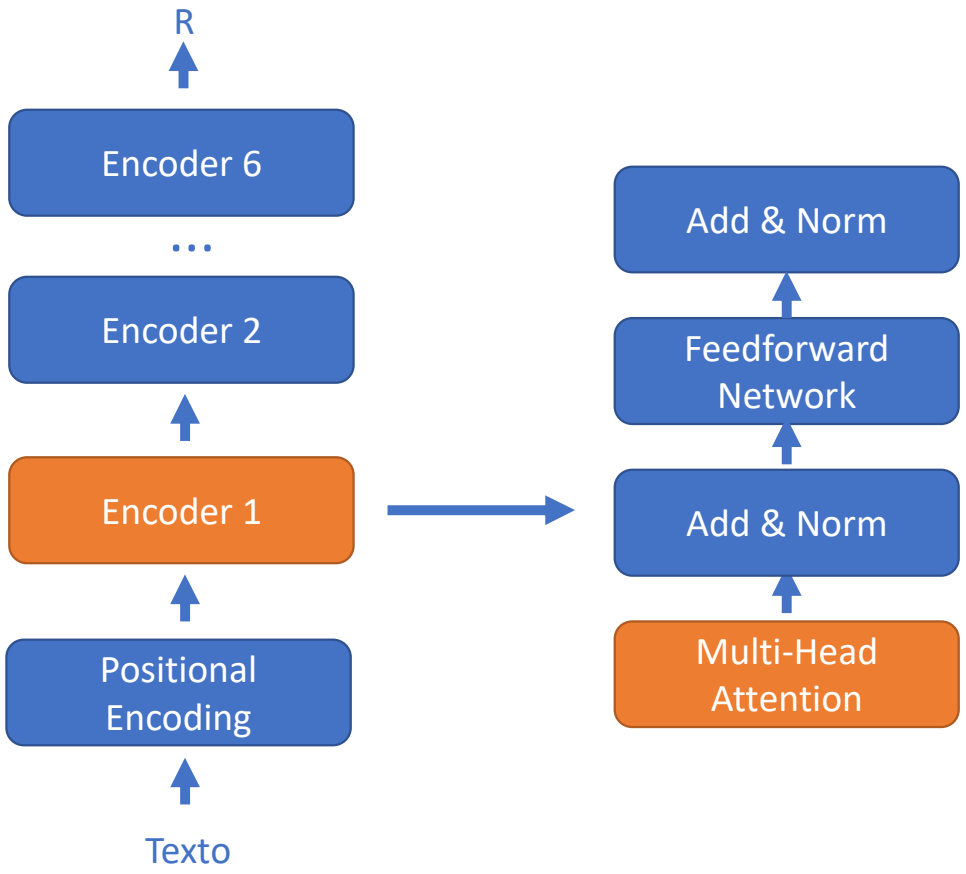
R
Encoder 6
...
Encoder 2
Encoder 1
Positional Encoding
Texto
Add & Norm
Feedforward Network
Add & Norm
Multi-Head Attention

Multi Attention

- Em vez de um processo Attention, múltiplos processos são processados e o resultado é somando
- Aumenta a precisão do sistema
- Todos as matrizes são concatenadas e multiplicadas por uma matriz ponderada, pois a RNA espera apenas uma matriz

Encoder

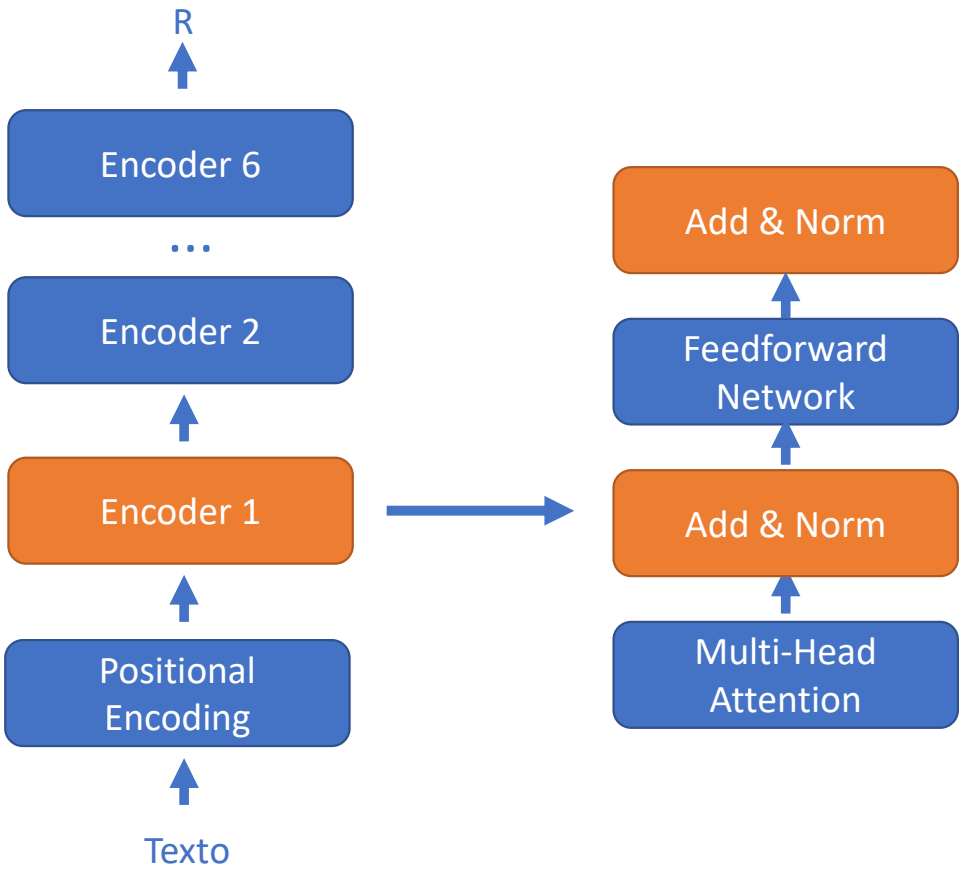
R
Encoder 6
...
Encoder 2
Encoder 1
Positional Encoding
Texto
Add & Norm
Feedforward Network
Add & Norm
Multi-Head Attention

Add & Norm

- Camada de Normalização
- Objetivo é conectar e normalizar
- Conecta a entrada do multi head attention com sua saída
- Conectada a entrada da feedforward com sua saída

Encoder

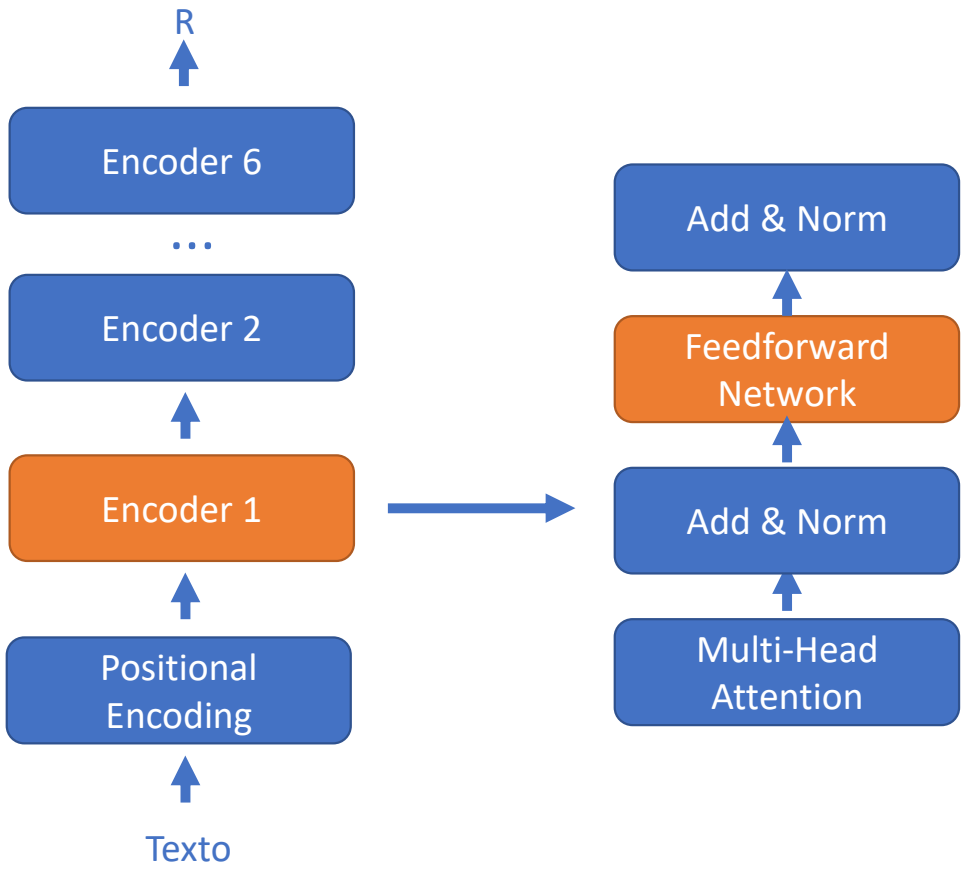
R
Encoder 6
...
Encoder 2
Encoder 1
Positional Encoding
Texto
Add & Norm
Feedforward Network
Add & Norm
Multi-Head Attention

Feedforward network

- Duas camadas densas com Relu